

AI Backlog Killer: ScrubSense

แผนเปลี่ยนงานค้างให้กลายเป็นงานที่ปิดได้จริง

โครงการ: ScrubSense — *An Automated Surgical Scrub Compliance Monitoring System*

บทบาทผู้รับผิดชอบ: Data Scientist – AI/ML

บริบท: Data Driven Department ของโรงพยาบาลขนาดใหญ่

อายุ Backlog: 1 เดือน

สถานะปัจจุบัน: ยังปิดงานไม่ได้ เนื่องจาก Accuracy ยังไม่เพียงพอ และมีงานอื่นแทรก

เป้าหมายเชิงกลยุทธ์: สนับสนุน Clinical Support และการพัฒนา AI ที่สามารถนำไปใช้งานจริงได้อย่างปลอดภัย

ข้อสรุปสำคัญก่อนเริ่ม

ปัญหาของ ScrubSense อาจไม่ได้อยู่ที่การเลือกโมเดลหรือเทคนิค ML เพียงอย่างเดียว แต่อาจอยู่ที่ การกำหนดเกณฑ์ความสำเร็จที่ยังไม่ชัดเจน การไม่มีชุดข้อมูลและวิธีประเมินมาตรฐาน และการไม่มีจุดตัดสินใจว่าจะปรับปรุงต่อหรือหยุดโครงการ

การแก้ Backlog จึงไม่ควรเป็นเพียง:

ทดลองโมเดลใหม่ → ได้ผลไม่ดี → ปรับวิธี → ทดลองใหม่

แต่ควรเปลี่ยนเป็น:

กำหนดเกณฑ์ผ่าน → ตรวจสอบข้อมูล → สร้าง Baseline → วิเคราะห์ข้อผิดพลาด → เลือกการทดลองที่มีเหตุผล → ตัดสินใจ Go / Iterate / Pivot / Stop

หลักการสำคัญ: Accuracy ที่ยังไม่ถึงเกณฑ์ ไม่ได้แปลว่าโครงการล้มเหลวเสมอไป แต่ต้องแยกให้ออกว่าเป็นปัญหาที่แก้ได้ด้วยข้อมูล เทคโนโลยี หรือข้อจำกัดของโจทย์ที่ควรปรับเปลี่ยน

ขอบเขตและข้อจำกัดของการวิเคราะห์

ข้อมูลที่มีในขณะนี้ระบุว่า ScrubSense เป็น งานค้าง 1 โครงการ ไม่ใช่รายการย่อยหลายงาน ดังนั้นการวิเคราะห์ต่อไปจะเน้นการแตกโครงการออกเป็น Work Packages และ Milestones เพื่อค้นหาว่าส่วนใดกำลังทำให้โครงการค้าง

ข้อมูลที่ยังไม่ได้รับการยืนยัน ได้แก่

- ค่า Accuracy ปัจจุบันและเป้าหมาย
- ประเภทข้อมูลที่ใช้ เช่น วิดีโอ ภาพ หรือข้อมูลจากระบบอื่น

- นิยามของ Surgical Scrub Compliance ที่ระบบต้องตรวจจับ
- วิธีตีคีย์กับข้อมูลและ Ground Truth
- Model / Architecture / Pipeline ที่ใช้อยู่
- จำนวนข้อมูลและการกระจายของเหตุการณ์
- เกณฑ์ยอมรับจากผู้เชี่ยวชาญทางคลินิก
- Deadline และผู้มีอำนาจอนุมัติ
- ข้อจำกัดด้าน PDPA ความลับผู้ป่วย และการใช้งานระบบในโรงพยาบาล

ดังนั้น รายงานนี้จะแยกให้ชัดเจนระหว่าง ข้อเท็จจริงที่ทราบแล้ว ข้อสันนิษฐาน และข้อเสนอแนะจากหลักการทางวิศวกรรม AI โดยจะไม่สร้างค่า Accuracy หรือผลการทดลองขึ้นมาเอง

1. Executive Summary

สถานการณ์ปัจจุบัน


หัวข้อ	สถานะ
โครงการ	ScrubSense
ประเภท	AI/ML Program
อายุงานค้าง	1 เดือน
จำนวนงานค้าง	1 โครงการ
ปัญหาหลักที่รายงาน Accuracy ยังไม่เพียงพอ	
ปัจจัยร่วม	มีงานอื่นแทรก
วิธีที่เคยลอง	Refine methods and techniques
อุปสรรคเชิงความรู้	ยังไม่มี Best Practice ที่ใช้เป็นแนวทาง
Owner	Data Scientist – AI/ML
Deadline	ยังไม่ระบุ
เกณฑ์ปิดงาน	ยังไม่ระบุ

Diagnosis เบื้องต้น

ScrubSense เป็นงานที่มี **ความไม่แน่นอนทางเทคนิคสูง** และมีความเสี่ยงด้านการนำไปใช้ในบริบททาง **คลินิก** จึงไม่ควรจัดการเหมือนงาน **CRUD** หรือ **Data Analysis** ทั่วไป

คอบวดที่น่าสงสัยมี 3 ระดับ:

Accuracy ยังไม่ผ่าน



ข้อเสนอเชิงกลยุทธ์

เปลี่ยนเป้าหมายจาก

ทำให้ **Accuracy** สูงขึ้นจนกว่าจะพอใจ

เป็น

สร้างหลักฐานเพื่อให้สามารถตัดสินใจได้ว่า **ScrubSense** ควรปรับปรุงต่อ เปลี่ยนขอบเขต ทดลองใช้งานแบบ
จำกัด หรือยุติการพัฒนา

นี่คือแนวทางที่เหมาะสมกว่าในสถานการณ์ที่ยังไม่มีเกณฑ์วัดผลและวิธีทดลองที่เป็นระบบ

Research Insight

สำหรับระบบ AI ที่อาจถูกใช้สนับสนุนงานในโรงพยาบาล ควรประเมินทั้งความถูกต้อง ความน่าเชื่อถือ ความปลอดภัย ความโปร่งใส และความสามารถในการตรวจสอบย้อนหลัง ไม่ใช่พิจารณา Accuracy เพียงตัวเดียว กรอบ NIST AI RMF เป็นแนวทางหนึ่งสำหรับการจัดการความเสี่ยงตลอดวงจรชีวิตของระบบ AI ([NIST](#))

ในด้าน Surgical Hand Preparation แนวทาง WHO ระบุขั้นตอนและเงื่อนไขที่เกี่ยวข้องกับการเตรียมมือก่อนสวมถุงมือปลอดเชื้อ เช่น วิธีการเตรียมมือ ระยะเวลาตามผลิตภัณฑ์ และการปฏิบัติตามคำแนะนำของผู้ผลิต อย่างไรก็ตาม แนวทางทางคลินิกไม่ได้แปลเป็น Label หรือเกณฑ์ Computer Vision ได้โดยอัตโนมัติ จำเป็นต้องให้ผู้เชี่ยวชาญกำหนด Operational Definition สำหรับระบบโดยเฉพาะ ([IRIS](#))

2. Backlog Diagnosis

2.1 งานค้างจริงคืออะไร?

จากข้อมูลที่มี งานค้างไม่ใช่เพียง “โมเดลยัง Accuracy ต่ำ” แต่เป็น:

ScrubSense ยังไม่มีหลักฐานเพียงพอที่จะยืนยันว่าโมเดลสามารถตรวจจับ **Surgical Scrub Compliance** ได้ตามเกณฑ์ที่ยอมรับได้ และยังไม่มีแผนตัดสินใจที่ชัดเจนเพื่อให้โครงการเดินหน้าหรือปิดอย่างมีเหตุผล

ต้องแยกงานออกเป็น 5 Work Packages:

WP งาน	ผลลัพธ์ที่ต้องการ	สถานะ
WP1 Clinical Definition	นิยาม Compliance ที่ตรวจได้	ยังไม่ทราบ
WP2 Data & Ground Truth	Dataset และ Label ที่เชื่อถือได้	ยังไม่ทราบ
WP3 Baseline & Evaluation	Benchmark และผลประเมิน	Accuracy ยังไม่ผ่าน
WP4 Error Analysis & Improvement	รายการข้อผิดพลาดและแผนแก้	ยังไม่ทราบ
WP5 Deployment Readiness	หลักฐานความพร้อมใช้งานและอนุมัติ	ยังไม่ทราบ

ขอขวดที่ต้องตรวจสอบก่อน

- Metric Bottleneck:** ใช้ Accuracy เป็นตัวชี้วัดหลัก ทั้งที่งานอาจต้องสนใจ Recall, Precision, F1, Event-level detection หรือ False Negative มากกว่า
- Data Bottleneck:** ข้อมูลไม่ครอบคลุมสภาพแวดล้อมจริง เช่น มุมกล้อง การบังมือ แสง หรือบุคลากรหลายรูปแบบ
- Label Bottleneck:** ผู้ติดป้ายกำกับอาจตีความ Compliance ไม่ตรงกัน

4. **Experiment Bottleneck:** ทดลองหลายวิธี แต่ไม่มี Experiment Log และเกณฑ์ตัดสินใจที่ชัดเจน

5. **Capacity Bottleneck:** มีงานอื่นแทรก ทำให้ไม่มีเวลาต่อเนื่องสำหรับแก้ปัญหาเชิงลึก

ข้อควรระวัง: ทั้ง 5 ข้อนี้เป็นสมมติฐานที่ต้องตรวจสอบ ไม่ใช่ Root Cause ที่ยืนยันแล้ว

3. Root Cause Analysis

3.1 Fact / Assumption / Missing Information

ประเภท	รายละเอียด
Fact	โครงการค้าง 1 เดือน
Fact	ผู้รับผิดชอบระบุว่า Accuracy ยังไม่เพียงพอ
Fact	มีงานอื่นแทรก
Fact	เคยปรับปรุง Methods และ Techniques
Fact	ยังไม่มี Best Practice ที่ใช้เป็นแนวทาง
Assumption	เกณฑ์ Accuracy ยังไม่ได้รับการตกลงอย่างชัดเจน
Assumption	ยังไม่มี Error Taxonomy ที่ใช้วิเคราะห์ปัญหาอย่างเป็นระบบ
Assumption	การทดลองที่ผ่านมาอาจยังไม่สามารถเปรียบเทียบกันได้อย่างยุติธรรม
Missing Information	Dataset, Label, Model, Metrics, Threshold, Deadline, Owner และ Acceptance Criteria

3.2 5 Whys

ปัญหา: ScrubSense ยังไม่สามารถปิดงานได้

Why	คำตอบเบื้องต้น	สถานะ
1	เพราะ Accuracy ยังไม่ถึงเกณฑ์	Fact จากข้อมูลที่ให้
2	เพราะโมเดลยังตรวจจับ Compliance ได้ไม่ดีพอ	ต้องตรวจหลักฐาน
3	เพราะอะไรจึงตรวจจับได้ไม่ดี?	ต้องทำ Error Analysis

Why คำตอบเบื้องต้น

สถานะ

4 ทำไมการปรับปรุงที่ผ่านมาไม่ทำให้ผ่าน?

ต้องตรวจ Experiment Log และข้อมูล

5 ทำไมจึงยังไม่สามารถระบุวิธีแก้ที่ชัดเจน?

อาจขาด Evaluation Framework และ Decision Gate

Root Cause ที่ควรใช้เป็น Working Hypothesis

กระบวนการพัฒนา ScrubSense ยังขาดระบบประเมินผลและตัดสินใจที่เป็นมาตรฐาน ทำให้การแก้ปัญหา Accuracy กลายเป็นการทดลองต่อเนื่องโดยไม่สามารถระบุได้ชัดเจนว่าอะไรคือสาเหตุของ Error และเมื่อใดจึงควรเปลี่ยนแนวทาง

นี่เป็น Working Hypothesis ไม่ใช่ Root Cause ที่ได้รับการพิสูจน์แล้ว

3.3 Process Bottleneck

รับโจทย์



พัฒนา Model



Accuracy ไม่ผ่าน



ลองวิธีใหม่



Accuracy ไม่ผ่าน



มีงานอื่นแทรก



หยุดชั่วคราว



กลับมาทดลองใหม่



ไม่มีหลักฐานสะสมที่น่ากลับมาใช้ได้เต็มที่

วิธีตัดวงจร

เพิ่มจุดควบคุม 4 จุด:

- **Definition Gate:** ตกลงว่าระบบต้องตรวจอะไร
- **Evaluation Gate:** ตกลง Metric และ Acceptance Criteria
- **Experiment Gate:** ทุกการทดลองต้องมี Hypothesis และผลลัพธ์
- **Decision Gate:** ตัดสินใจตามหลักฐาน ไม่ใช่ความรู้สึก

3.4 Backlog จะเกิดซ้ำตรงไหน?

หากยังใช้วิธีเดิม มีโอกาสเกิดซ้ำเมื่อ:

- เริ่มงานโดยไม่มี Definition of Done
- ไม่มีเวลาเฉพาะสำหรับโครงการที่มีความซับซ้อนสูง
- ทดลองโมเดลโดยไม่เก็บผลอย่างเป็นระบบ
- ไม่มีผู้เชี่ยวชาญด้าน Clinical ร่วมกำหนด Ground Truth
- ใช้ Metric เดียวตัดสินระบบที่มีหลายประเภทของ Error
- ไม่มีขอบเขตว่าเมื่อใดต้องหยุดทดลองและขอการตัดสินใจ

4. COLLECT — Backlog Data Checklist

ก่อนปรับปรุงโมเดล ควรสร้าง **ScrubSense Evidence Pack** ซึ่งเป็นชุดข้อมูลและหลักฐานที่ใช้ตัดสินใจร่วมกันระหว่าง Data, AI และ Clinical

A–E. รายการข้อมูลที่ต้องรวบรวม

หมวด	รายการ	ความสำคัญ	สถานะ
Must Have	Clinical Definition ของ Scrub Compliance	สูงมาก	Missing
Must Have	Acceptance Criteria ที่ได้รับการอนุมัติ	สูงมาก	Missing
Must Have	Dataset ที่ใช้ Train / Validation / Test	สูงมาก	Missing

หมวด	รายการ	ความสำคัญ สถานะ	
Must Have	Ground Truth และ Annotation Guideline	สูงมาก	Missing
Must Have	Model Version และ Pipeline Version	สูงมาก	Missing
Must Have	ผลการประเมินแยกตาม Test Set	สูงมาก	Missing
Must Have	Error Analysis	สูงมาก	Missing
Must Have	Data Split และป้องกัน Data Leakage	สูงมาก	Missing
Must Have	รายละเอียดการใช้งานเป้าหมาย	สูงมาก	Missing
Nice to Have	Experiment Tracking	สูง	ไม่ทราบ
Nice to Have	Confusion Matrix	สูง	ไม่ทราบ
Nice to Have	Performance แยกตามสภาพแสง/มุมกล้อง	สูง	ไม่ทราบ
Nice to Have	Ablation Study	กลาง	ไม่ทราบ
Nice to Have	Benchmark จากวิธีอื่น	กลาง	ไม่ทราบ
Nice to Have	Labeler Agreement	สูง	ไม่ทราบ
Nice to Have	Model Explainability / Visual Debugging	กลาง	ไม่ทราบ
Unreliable Data	Label ที่ผู้ประเมินเห็นไม่ตรงกัน	สูง	ต้องตรวจ
Unreliable Data	Video ที่มีภาพบังหรือมองไม่เห็นมือ	สูง	ต้องตรวจ
Unreliable Data	Dataset ที่มีเหตุการณ์ซ้ำใน Train และ Test	สูงมาก	ต้องตรวจ
Unreliable Data	Metric จาก Test Set ที่เปลี่ยนไปมา	สูง	ต้องตรวจ
Unreliable Data	Annotation ที่ไม่มี Version Control	สูง	ต้องตรวจ

Data Sources ที่ควรค้นเพิ่มเติม

1. Clinical / Infection Prevention Team — นิยามและขั้นตอนที่ถูกต้อง
2. Operating Room / Surgical Scrub Area — สภาพแวดล้อมจริงและข้อจำกัดของกล้อง

3. Dataset Repository — ข้อมูลวิดีโอ ภาพ และ Metadata ที่ได้รับอนุญาต
4. Annotation Records — Label และเหตุผลที่ใช้กำหนด Label
5. Git / MLflow / Experiment Tracking — ประวัติ Model และการทดลอง
6. Internal SOP / Clinical Policy — ขั้นตอนที่ต้องกรอข้อมูล
7. Security / PDPA / IT Governance — เงื่อนไขการจับเก็บและประมวลผลข้อมูล

Checklist ที่ใช้ได้ทันที

- ☐ มี Clinical Definition ที่ผู้เชี่ยวชาญอนุมัติ
- ☐ นิยาม Positive / Negative / Unclear ครบ
- ☐ มี Annotation Guideline
- ☐ มีผู้ตรวจ Label ที่เหมาะสม
- ☐ มี Dataset Version
- ☐ แยก Train / Validation / Test อย่างถูกต้อง
- ☐ ป้องกัน Leakage ระหว่างวิดีโอ/บุคคล/เหตุการณ์
- ☐ มี Baseline Model
- ☐ มี Evaluation Script ที่ทำซ้ำได้
- ☐ มี Metric ที่เหมาะสมกับโจทย์
- ☐ มี Confusion Matrix หรือ Event-level Error
- ☐ มี Error Taxonomy
- ☐ มี Experiment Log
- ☐ มีข้อมูลสภาพแวดล้อมที่เกี่ยวข้อง
- ☐ ตรวจสอบสิทธิ์การใช้ข้อมูล
- ☐ มี Data Retention และ Access Control
- ☐ มี Clinical Reviewer
- ☐ มี Acceptance Criteria

[] มีผู้อนุมัติผล

[] มี Decision Gate

เกณฑ์หยุดการปรับโมเดลชั่วคราว: หากยังไม่มี Clinical Definition, Ground Truth หรือ Test Set ที่เชื่อถือได้ ควรแก้ Evidence Gap ก่อน เพราะการเพิ่มความซับซ้อนของโมเดลอาจไม่ช่วยให้ทราบว่าระบบดีขึ้นจริงหรือไม่

5. CLASSIFY — จัดหมวดหมู่งาน

เนื่องจากมีงานค้าง 1 โครงการ การจัดหมวดหมู่จะใช้ Work Packages แทนการจัดกลุ่มหลายโครงการ

Work Package	ความซับซ้อน ความเร่งด่วน ผลกระทบ ความเสี่ยง AI ทำได้				
Clinical Definition	กลาง	สูง	สูง	สูง	ช่วยเตรียม
Data Audit	สูง	สูง	สูง	สูง	ช่วยมาก
Baseline Evaluation	สูง	สูง	สูง	สูง	ช่วยมาก
Error Analysis	สูง	สูง	สูง	สูง	ช่วยมาก
Model Improvement	สูงมาก	กลาง	สูง	สูงมาก	ช่วยพัฒนา
Documentation	กลาง	กลาง	กลาง	กลาง	ทำได้มาก
Clinical Validation	สูง	สูง	สูงมาก	สูงมาก	ช่วยเตรียม
Deployment Approval	สูง	ตามแผน	สูงมาก	สูงมาก	ทำแทนไม่ได้

การแบ่ง 4 กลุ่ม

1. AI ทำได้ทันที

- สร้าง Experiment Log Template
- สร้าง Data Inventory
- สรุปผลการทดลองจากไฟล์ที่มี
- สร้าง Evaluation Script Draft
- สร้าง Error Taxonomy Draft

- สร้าง Checklist และ Risk Register
- สร้างเอกสาร Technical Documentation

2. AI ช่วยเตรียม แต่คนต้องตรวจ

- วิเคราะห์ Confusion Matrix
- สรุป False Positive / False Negative
- เสนอ Hypothesis เพื่อแก้ Error
- ร่าง Annotation Guideline
- วิเคราะห์ผลการทดลองหลาย Version
- ร่าง Clinical Validation Plan
- สร้างรายงานสำหรับผู้บริหาร

3. คนต้องตัดสินใจ

- นิยามว่าอะไรคือ Compliance
- กำหนดเกณฑ์ผ่าน
- ยอมรับ Trade-off ระหว่าง Precision และ Recall
- อนุมัติ Clinical Use Case
- อนุมัติการใช้ข้อมูลจริง
- อนุมัติ Go / No-Go
- รับรองความเหมาะสมก่อนใช้งานจริง

4. ยังทำไม่ได้เพราะขาดข้อมูลหรือข้อจำกัด

- ยืนยันว่าโมเดลผ่าน Accuracy ที่กำหนด
- ยืนยันความพร้อมใช้งานจริง
- สรุปว่าโมเดลปลอดภัยสำหรับ Clinical Deployment
- รับรองว่าระบบไม่มี Bias ที่มีความสำคัญ
- ประเมินผลกระทบต่อผู้ป่วยโดยไม่มีข้อมูลการใช้งานจริง

6. PRIORITIZE — Priority Matrix

เนื่องจากยังไม่มีข้อมูลเชิงปริมาณ คะแนนต่อไปนี้เป็น คะแนนเบื้องต้นเพื่อจัดลำดับงาน ไม่ใช่ผลประเมินที่ยืนยันแล้ว

คะแนน 1–5: 5 หมายถึงระดับสูง

สำหรับ Effort และ Dependency: 5 หมายถึงใช้แรงมากหรือพึ่งพางานอื่นมาก

Work Package	Impact	Urgency	Risk	Effort	AI Leverage	Dependency	ข้อเสนอ
Clinical Definition	5	5	5	2	3	5	ทำก่อน
Data Audit	5	5	5	3	4	5	ทำก่อน
Baseline Evaluation	5	5	5	3	4	5	ทำก่อน
Error Analysis	5	4	5	4	4	4	ทำต่อ
Model Improvement	5	3	5	5	3	3	ทำหลังรู้ Root Cause
Documentation	3	3	3	2	5	2	Automate
Clinical Validation	5	4	5	4	2	5	ต้องมีผู้เชี่ยวชาญ
Deployment Approval	5	3	5	3	1	5	Escalate เมื่อพร้อม

ลำดับที่แนะนำ

ทำก่อน

1. Clinical Definition
2. Data Audit
3. Baseline Evaluation
4. Error Analysis
5. Decision Gate

ทำทีหลัง

- Model Improvement ที่ใช้เวลามาก

- การเพิ่ม Architecture ที่ซับซ้อน
- การพัฒนา Feature ที่ยังไม่เชื่อมโยงกับ Error ที่พบ

ควรหยุดชั่วคราว

- ทดลองโมเดลใหม่โดยไม่มี Hypothesis
- ปรับ Hyperparameter โดยไม่มี Baseline เปรียบเทียบ
- เพิ่มข้อมูลโดยไม่ตรวจ Label Quality
- ทำ UI เพิ่มก่อนยืนยันความสามารถของ Core Model

Automate

- Evaluation Pipeline
- Metric Calculation
- Experiment Logging
- Dataset Versioning
- Report Generation
- Regression Test

Delegate

- Dataset Inventory
- Annotation Quality Audit
- Documentation
- Dashboard สำหรับติดตามผล
- Data Cleaning ที่มีกฎชัดเจน

Escalate

- ไม่มี Clinical Owner
 - ไม่สามารถกำหนด Acceptance Criteria
 - ไม่มีสิทธิ์ใช้ข้อมูล
 - ต้องตัดสินใจเปลี่ยน Scope
 - โครงการกระทบงานสำคัญอื่นและไม่มี Capacity
-

7. Quick Wins — 20% ที่อาจลด Backlog ได้มากที่สุด

ในกรณีนี้ Quick Win ไม่จำเป็นต้องเป็นการเพิ่ม Accuracy ทันที แต่คือการลดความไม่แน่นอนที่ทำให้โครงการเดินต่อไปไม่ได้

Quick Win 1: สร้าง One-Page Project Decision Brief

ภายในเอกสารเดียวให้ตอบ:

- ระบบต้องตรวจอะไร?
- ใครเป็นผู้ใช้?
- อะไรคือ Compliance?
- Accuracy หรือ Metric เท่าใดจึงถือว่าผ่าน?
- ใช้ข้อมูลชุดใด?
- Error หลักคืออะไร?
- การทดลองครั้งถัดไปมี Hypothesis อะไร?
- ใครเป็นผู้ตัดสินใจ Go / No-Go?

ผลลัพธ์: ลดการตีความโจทย์ไม่ตรงกัน

Quick Win 2: Freeze Baseline

กำหนด Model Version หนึ่งเป็น Baseline และหยุดการเปลี่ยนโมเดลแบบไร้กรอบชั่วคราว

ผลลัพธ์: ทุกการปรับปรุงหลังจากนี้ต้องพิสูจน์ว่าเหนือกว่า Baseline

Quick Win 3: สร้าง Error Analysis Report

แบ่ง Error เป็นหมวด เช่น:

- มองไม่เห็นมือ
- มือถูกบัง
- แสงไม่เหมาะสม
- บุคลากรหลายคน
- ขั้นตอนคล้ายกัน
- Label ไม่ชัด

- Temporal Context ไม่เพียงพอ
- False Positive
- False Negative

ผลลัพธ์: เปลี่ยนจาก “ลองวิธีใหม่” เป็น “แก้ปัญหาที่ระบุได้”

Quick Win 4: Automate Evaluation

สร้าง Script เดียวที่รับ Model Prediction และ Ground Truth แล้วสร้าง:

- Metric Summary
- Confusion Matrix
- Error Samples
- Result by Scenario
- Comparison กับ Baseline

ผลลัพธ์: ลดเวลาประเมินซ้ำและลดความผิดพลาดจากการคำนวณ

Quick Win 5: กำหนด Decision Gate

เมื่อจบ Sprint ให้เลือกอย่างใดอย่างหนึ่ง:

ผลการประเมิน	การตัดสินใจ
ผ่านเกณฑ์	เข้าสู่ Validation
ดีขึ้นแต่ยังไม่ผ่าน	ทำ Improvement ที่มีหลักฐาน
ไม่ดีขึ้น	เปลี่ยน Hypothesis หรือ Scope
ขาดข้อมูลสำคัญ	หยุดพัฒนาโมเดลชั่วคราวและแก้ Data Gap

ความเสี่ยงสูง/ไม่คุ้มค่า เสนอหยุดหรือยุติโครงการ

หมายเหตุ: ยังไม่สามารถยืนยันว่า Quick Wins เหล่านี้จะลด Backlog ได้ 80% เพราะยังมีเพียงหนึ่งโครงการ และยังไม่มีข้อมูลเวลาหรือจำนวน Work Items

8. ANALYZE — วิเคราะห์ทางเลือกด้าน AI/ML

8.1 สิ่งที่ต้องตรวจสอบก่อนเปลี่ยน Model

กรณีที่ 1: Metric ไม่เหมาะกับโจทย์

Accuracy อาจไม่สะท้อนความสามารถของระบบอย่างเพียงพอ โดยเฉพาะเมื่อจำนวนเหตุการณ์ที่ **Compliance** และ **Non-compliance** ไม่สมดุล

ควรพิจารณา:

Metric	ใช้ตอบคำถามอะไร
Accuracy	ทำนายถูกทั้งหมดกี่เปอร์เซ็นต์
Precision	เมื่อระบบแจ้งว่าไม่ผ่าน มีโอกาสถูกต้องเท่าใด
Recall / Sensitivity	ระบบตรวจจับเหตุการณ์ที่ต้องการได้ครบเพียงใด
Specificity	ระบบแยกเหตุการณ์ที่ไม่ใช่ Compliance ได้ดีเพียงใด
F1-score	สมดุลระหว่าง Precision และ Recall
Confusion Matrix	ผิดประเภทใดมากที่สุด
Event-level Recall	ตรวจจับเหตุการณ์สำคัญได้ครบเพียงใด
False Alarm Rate	ระบบแจ้งเตือนผิดบ่อยเพียงใด
Latency	ระบบใช้เวลาตรวจจับนานเท่าใด

ข้อเสนอ: อย่าเปลี่ยนจาก **Accuracy** ไปใช้ **Metric** อื่นโดยอัตโนมัติ ต้องให้ **Clinical Owner** และทีม **AI** ร่วมกำหนดว่า **Error** ประเภทใดมีผลกระทบสูงสุด

8.2 กรณีที่ 2: ปัญหายุ่งที่ Data

แนวทางที่ควรทดลอง:

- ตรวจ Class Distribution
- ตรวจ Label Quality
- ตรวจความหลากหลายของมุมมอง
- ตรวจแสง เงา และ Occlusion
- ตรวจความหลากหลายของบุคคลากร
- แยก Performance ตาม Scenario
- ตรวจ Data Leakage

- เพิ่ม Hard Negative Samples
- เพิ่มข้อมูลเฉพาะ Error ที่พบจริง

8.3 กรณีที่ 3: ปัญหาอยู่ที่ Model

ค่อยพิจารณา:

- Baseline CNN / Vision Model
- Object Detection
- Pose / Hand Tracking
- Temporal Model
- Video Transformer
- Multi-stage Pipeline
- Rule-based Post-processing
- Ensemble
- Confidence Calibration

การเลือกวิธีควรขึ้นกับประเภทของ Error ไม่ใช่ความใหม่ของ Architecture

8.4 กรณีที่ 4: ปัญหาอยู่ที่นิยามของ Compliance

อาจจำเป็นต้องเปลี่ยนจากโจทย์:

ตรวจว่าบุคลากร Scrub ถูกต้องหรือไม่

เป็นโจทย์ย่อยที่ตรวจสอบได้ เช่น:

- ตรวจว่ามีอยู่ภายในบริเวณที่ต้องการหรือไม่
- ตรวจว่ามีเคลื่อนไหวตามขั้นตอนหรือไม่
- ตรวจว่าขั้นตอนหนึ่งเกิดขึ้นหรือไม่
- ตรวจเหตุการณ์ที่ต้องการให้มนุษย์ทบทวน

ข้อควรระวัง: การแบ่งโจทย์ย่อยต้องได้รับการยืนยันจากผู้เชี่ยวชาญ ไม่ควรลดความซับซ้อนจนไม่ตอบโจทย์ Clinical ที่แท้จริง

9. REDESIGN — Future-State Workflow

9.1 Workflow เดิมโดยสันนิษฐาน

รับโจทย์



พัฒนา Model



ทดลอง



Accuracy ไม่ผ่าน



Refine Methods



ทดลองใหม่



มีงานอื่นแทรก



งานค้าง

9.2 Workflow ใหม่แบบ Zero-Based

[1] Clinical Problem Definition



[2] Acceptance Criteria & Risk Definition



[3] Data Audit + Ground Truth Audit



[4] Baseline Model + Reproducible Evaluation



[5] Error Analysis



[6] Prioritized Experiment Backlog




[7] Time-boxed Experiment Sprint




[8] Evaluation + Statistical / Scenario Review



[9] Decision Gate



Improve Pivot Stop



Clinical Validation



Limited Pilot / Approval



Close-out

9.3 ขั้นตอนที่ควรตัดทิ้ง

- การทดลองโดยไม่มี Hypothesis
- การปรับ Model โดยไม่เก็บ Version
- การประเมินจากข้อมูลชุดเดียวโดยไม่มีการแบ่งข้อมูลที่เหมาะสม
- การใช้ Accuracy เพียงค่าเดียวโดยไม่วิเคราะห์ Error
- การพัฒนา Deployment ก่อนมีหลักฐานว่า Core Model ทำงานได้ตามเป้าหมาย

9.4 ขั้นตอนที่ควรรวม

- Data Audit + Label Audit
- Evaluation + Error Analysis
- Experiment Log + Decision Log
- Documentation + Evidence Collection

9.5 สิ่งที่ AI ควรทำ

- วิเคราะห์ผลการทดลอง

- จัดกลุ่ม Error
- สร้างโค้ดประเมินผล
- เสนอ Hypothesis
- สร้าง Experiment Plan
- สร้างรายงาน
- สรุปความแตกต่างระหว่าง Model Version
- ตรวจสอบความครบถ้วนของหลักฐาน

9.6 สิ่งที่มีมนุษย์ต้องรับผิดชอบ

- Clinical Definition
- การกำหนดความเสี่ยงที่ยอมรับได้
- การรับรอง Label
- การตัดสินใจเลือก Scope
- การอนุมัติข้อมูล
- การรับรองผล Validation
- การอนุมัติใช้งานจริง

9.7 จุดที่ต้องมี Approval

จุด	ผู้อนุมัติที่ควรมี
Clinical Definition	Clinical Owner / Infection Prevention
Data Access	Data Owner / Security / PDPA ตามนโยบายองค์กร
Annotation Guideline	Clinical Reviewer
Acceptance Criteria	Project Owner + Clinical Owner
Validation Plan	Clinical และ AI Lead
Pilot	หน่วยงานที่รับผิดชอบ + Governance ที่เกี่ยวข้อง
Production Deployment	ผู้มีอำนาจอนุมัติระบบตามนโยบายโรงพยาบาล

10. GENERATE DRAFT — ตัวอย่างเอกสารที่ AI สร้างได้

10.1 Draft: ScrubSense Decision Brief

สถานะ: Draft — ยังไม่ผ่านการตรวจสอบ

Project Objective

พัฒนาระบบ Automated Surgical Scrub Compliance Monitoring เพื่อช่วยตรวจสอบเหตุการณ์หรือพฤติกรรมที่เกี่ยวข้องกับการเตรียมมือก่อนการผ่าตัด ตามนิยามที่ได้รับการอนุมัติจากผู้เชี่ยวชาญทางคลินิก

Current Status

- โครงการอยู่ระหว่างการพัฒนา
- อายุงานค้าง: 1 เดือน
- Accuracy ยังไม่ถึงเกณฑ์ที่ยอมรับได้
- มีการปรับปรุง Methods และ Techniques แล้ว
- ยังขาดข้อมูลสำหรับระบุสาเหตุของ Error อย่างเป็นระบบ

Key Risks

- ยังไม่มี Acceptance Criteria ที่ยืนยันแล้ว
- ยังไม่ทราบความน่าเชื่อถือของ Ground Truth
- ยังไม่ทราบว่า Error หลักเกิดจาก Data หรือ Model
- อาจเกิด False Negative ในเหตุการณ์ที่มีความสำคัญ
- การใช้งานข้อมูลวิดีโอในโรงพยาบาลอาจมีข้อจำกัดด้านความเป็นส่วนตัว

Decision Required

ต้องการการตัดสินใจในเรื่อง:

- Clinical Definition
- Target Metrics
- Test Dataset
- Validation Approach
- Deadline
- Clinical Owner

- Go / Iterate / Pivot / Stop Criteria

Missing Evidence

ต้องการข้อมูลเพิ่มเติม: Dataset Summary, Model Version, Accuracy ปัจจุบัน, Target Metric, Error Analysis, Clinical Definition, Deadline และผู้อนุมัติ

10.2 Draft: Experiment Card

รายการ	ตัวอย่างที่ต้องการออก
Experiment ID	SCRUB-EXP-001
Hypothesis	ต้องการข้อมูลเพิ่มเติม
Problem Addressed	ต้องการข้อมูลเพิ่มเติม
Baseline	ต้องการ Model Version
Data Version	ต้องการข้อมูลเพิ่มเติม
Change	ต้องการข้อมูลเพิ่มเติม
Expected Improvement	ต้องการเกณฑ์ที่ตกลง
Metrics	ต้องการข้อมูลเพิ่มเติม
Result	ยังไม่มีหลักฐาน
Error Change	ยังไม่มีหลักฐาน
Decision	Pending Review
Owner	Data Scientist
Reviewer	ต้องระบุ
Next Action	จัดทำ Baseline และ Error Analysis

10.3 Draft: Executive Summary

ScrubSense เป็นโครงการ AI/ML สำหรับสนับสนุนการตรวจสอบ Surgical Scrub Compliance ซึ่งยังไม่สามารถปิดงานได้เนื่องจากผล Accuracy ยังไม่เพียงพอ

จากการประเมินเบื้องต้น ควรหยุดการทดลองแบบไร้กรอบชั่วคราว และจัดทำ Clinical Definition, Evaluation Framework, Baseline และ Error Analysis ให้ครบก่อนเริ่ม Model Improvement รอบถัดไป

การตัดสินใจเกี่ยวกับการพัฒนาต่อ การเปลี่ยน Scope หรือการยุติโครงการควรอ้างอิงหลักฐานด้านประสิทธิภาพ ความเสี่ยง และความคุ้มค่า โดยมีผู้เชี่ยวชาญทางคลินิกร่วมตัดสินใจ

11. VERIFY — ระบบตรวจงาน AI

11.1 Verification Matrix

ประเด็น	สิ่งที่ต้องตรวจ	สถานะ
Accuracy	คำนวณจาก Ground Truth ที่เหมาะสม	⚠️ Need Review
Completeness	ข้อมูลและ Scenario ครบหรือไม่	⚠️ Need Review
Source	Dataset และเอกสารมีที่มาชัดเจน	⚠️ Need Review
Date	Dataset และ Model Version เป็นปัจจุบัน	⚠️ Need Review
Context	ใช้ในสภาพแวดล้อมที่ตรงกับเป้าหมายหรือไม่	⚠️ Need Review
Calculation	Script คำนวณ Metric ถูกต้อง	⚠️ Need Review
Logic	การแปลผลสอดคล้องกับ Metric	⚠️ Need Review
Contradiction	ผลทดลองและเอกสารขัดแย้งกันหรือไม่	⚠️ Need Review
Legal / Compliance	มีสิทธิใช้ข้อมูลและปฏิบัติตามนโยบาย	⚠️ Need Review
Privacy	ข้อมูลผู้ป่วยและบุคลากรได้รับการคุ้มครอง	⚠️ Need Review

ไม่มีผลประเมินจริงในข้อมูลปัจจุบัน จึงยังไม่สามารถทำเครื่องหมาย **Verified** ให้กับ Performance ของโมเดลได้

11.2 AI Quality Gate

Input



ตรวจ Dataset Version



ตรวจ Ground Truth



ตรวจ Model Version



ตรวจ Evaluation Script



คำนวณ Metrics



วิเคราะห์ Error



ตรวจ Data Leakage



ตรวจ Scenario Coverage



ตรวจ Compliance / Privacy



Human Review



Approved / Revise / Reject

11.3 สิ่งที่มีมนุษย์ต้องตรวจสอบ

- ความถูกต้องของ Clinical Definition
- ความถูกต้องของ Label
- ความเหมาะสมของ Acceptance Criteria
- False Negative ที่อาจมีผลกระทบสูง
- ความถูกต้องของการตีความผลการทดลอง
- ความเหมาะสมในการใช้ระบบในสภาพแวดล้อมจริง

- ความสอดคล้องกับกฎระเบียบและนโยบายโรงพยาบาล

12. CLOSE — Definition of Done

ScrubSense ไม่ควรถือว่า “เสร็จ” เพียงเพราะมีโมเดลหรือมีหน้าเว็บใช้งานได้

12.1 Definition of Done ที่เสนอ

ระดับ A: Technical Baseline Complete

- มี Clinical Definition ที่ชัดเจน
- มี Dataset Version
- มี Ground Truth
- มี Baseline Model
- มี Evaluation Pipeline
- มี Metric Report
- มี Error Analysis
- มี Experiment Log

ระดับ B: Model Evaluation Complete

- ผ่าน Acceptance Criteria ที่ได้รับการอนุมัติ
- ทดสอบบนข้อมูลที่เหมาะสม
- ตรวจ Data Leakage
- ตรวจ Performance แยกตาม Scenario
- มีผลการทดลองที่ทำซ้ำได้
- มีผู้ตรวจสอบผล

ระดับ C: Clinical Validation Complete

- มี Clinical Reviewer
- มี Validation Plan
- มี Risk Assessment

- มี Privacy / Security Review
- มีหลักฐานว่าเหมาะสมกับ Use Case
- ได้รับการอนุมัติจากผู้มีอำนาจ

ระดับ D: Project Close

- มี Decision: Deploy / Pilot / Pivot / Stop
- มี Technical Documentation
- มี Model Card
- มี Dataset Card
- มี Experiment Archive
- มี Risk Register
- มี Decision Log
- มีผู้อนุมัติการปิดงาน
- มี Next Step หากโครงการยังไม่พร้อมใช้งานจริง

12.2 Close-out Checklist

- [] Scope ได้รับการยืนยัน
- [] Acceptance Criteria ได้รับการอนุมัติ
- [] Dataset และ Label ได้รับการตรวจ
- [] Model Version ถูกบันทึก
- [] Evaluation Report เสร็จ
- [] Error Analysis เสร็จ
- [] Risk Assessment เสร็จ
- [] Privacy / Security Review เสร็จ
- [] Clinical Review เสร็จ
- [] Decision Gate ผ่าน

[] เอกสารจัดเก็บครบ

[] Owner รับมอบงาน

[] ผู้อนุมัติลงนาม

[] มีวันปิดงาน

สถานะปัจจุบัน: ยังไม่สามารถประกาศว่า ScrubSense ผ่าน Definition of Done ได้ เนื่องจากหลักฐานสำคัญยังไม่ครบ

13. BACKLOG ที่ปิดไม่ได้

สำหรับ ScrubSense การจัดหมวด Backlog ที่เหมาะสมคือการแยก **สิ่งที่ขัดขวางการปิดงาน** ออกจากตัวโครงการหลัก

หมวด	สาเหตุที่อาจเกิดขึ้น	ทางเลือก	Owner ที่ควรรับผิดชอบ	Next Action	Escalation
A. รวบรวมข้อมูล	Dataset หรือ Label ไม่ครบ	ขอข้อมูลเพิ่มเติม / ลด Scope	Data Scientist + Data Owner	ทำ Data Gap List	Data Lead
B. รวบรวมความคิดเห็น	ยังไม่กำหนด Compliance หรือ Metric	นัด Decision Meeting	Clinical Owner + Project Owner	ส่ง Decision Brief	Department Head
C. รวบรวม Approval	ยังไม่มีสิทธิ์ใช้ข้อมูลหรือ Pilot	ขออนุมัติตามขั้นตอน	Project Owner	จัดทำ Approval Package	Governance Lead
D. ข้อกำหนดระบบ	กล่องหรือ Compute ไม่เพียงพอ	ปรับ Architecture / Pilot จำกัด	ML Engineer / IT	ทำ Technical Feasibility	IT Lead
E. ข้อกำหนดกฎหมาย	ความเป็นส่วนตัวหรือสิทธิ์ข้อมูล	De-identification / เปลี่ยนวิธีเก็บข้อมูล	Security / Privacy / Legal	ตรวจสอบข้อกำหนด	ผู้รับผิดชอบ Compliance
F. Dependency	ต้องพึ่ง Clinical, Data หรือ IT	จัดลำดับ Dependency	Project Owner	ทำ Dependency Register	Project Sponsor

หมวด	สาเหตุที่อาจเกิดขึ้น	ทางเลือก	Owner ที่ควรรับผิดชอบ	Next Action	Escalation
G. ไม่มี Owner	ไม่มีผู้รับผิดชอบ การตัดสินใจ	แต่งตั้ง Owner	Department Head	ระบุ RACI	Sponsor
H. ไม่จำเป็นอีกต่อไป	Use Case ไม่ ตอบโจทย์หรือไม่ คุ้มค่า	Pivot / Stop	Project Sponsor	ทำ Value Review	Steering Committee

หลักการสำคัญ

งานที่รอข้อมูลหรือรอการตัดสินใจ ไม่ควรถูกนับเป็นงานที่ **Data Scientist** ต้องแก้ด้วยการเขียนโค้ดเพิ่มเสมอไป

ควรเปลี่ยนสถานะเป็น:

- Blocked – Data
- Blocked – Decision
- Blocked – Approval
- Blocked – Dependency
- Ready for Experiment
- Ready for Validation
- Ready for Closure

14. AI TOOL MAPPING

ขั้นตอน	เครื่องมือประเภท	Input	Output	ต้องตรวจสอบอะไร
Collect	Chat AI / Document AI	SOP, Notes, เอกสารโครงการ	Data Checklist	ความครบถ้วนและที่มา
Clinical Definition	Chat AI + Human Review	Clinical SOP, คำอธิบายขั้นตอน	Definition Draft	Clinical Accuracy
Data Audit	Data Analysis / Python	Dataset Metadata, Labels	Data Quality Report	Leakage, Missingness, Bias

ขั้นตอน	เครื่องมือประเภท	Input	Output	ต้องตรวจอะไร
Model Evaluation	Coding AI + Python	Predictions, Ground Truth	Metrics, Confusion Matrix	Calculation
Error Analysis	Vision Analysis / Data Analysis	Error Samples, Metadata	Error Taxonomy	การตีความภาพและบริบท
Experiment Planning	Chat AI / Deep Research	Baseline, Error Report	Experiment Cards	ความเป็นไปได้
Model Improvement	Coding AI	Codebase, Experiment Card	Code / Model Draft	Code Review, Reproducibility
Documentation	Chat AI	Logs, Reports, Decisions	Model Card, SOP, Summary	Source และ Version
Workflow	Automation	Status, Deadline, Owner	Reminder, Dashboard	สิทธิ์และการส่งข้อมูล
Executive Reporting	Chat AI / Presentation AI	Evidence Pack	Decision Brief	ห้ามแต่งตัวเลข
Validation	Data Analysis + Clinical Review	Test Results	Validation Report	Human Sign-off

ข้อเสนอการใช้ AI ที่คุ้มค่าที่สุด

1. Coding AI

เหมาะกับการสร้าง:

- Evaluation Script
- Data Validation
- Regression Test
- Experiment Tracking
- Error Sampling
- Metric Dashboard

2. Chat AI

เหมาะกับการ:

- สรุปผลการทดลอง
- แปลงผลวิเคราะห์เป็น Decision Brief

- ตรวจสอบความครบถ้วนของเอกสาร
- สร้าง Checklist
- จัดโครงสร้าง Backlog

3. Deep Research

เหมาะกับ:

- ค้นหาแนวทาง Computer Vision สำหรับ Surgical Hand Preparation
- เปรียบเทียบวิธีประเมิน Video Understanding
- ค้นหา Best Practice ด้าน Clinical AI Validation
- ศึกษาแนวทาง Data Governance และ AI Risk Management

ไม่ควรใช้ Deep Research แทนการทดสอบโมเดลกับข้อมูลจริงของโรงพยาบาล

4. Automation

เหมาะกับ:

- แจ้งเตือนเมื่อ Experiment ครบกำหนด
- สร้างรายงานผลอัตโนมัติ
- ตรวจสอบว่า Dataset Version เปลี่ยนหรือไม่
- แจ้งเตือนเมื่อ Metric ต่ำกว่า Threshold
- สรุปสถานะ Backlog รายสัปดาห์

15. KPI — Before / After

เนื่องจากยังไม่มี Baseline เติงปริมาณ จึงควรบันทึกค่าจริงก่อนเริ่มแผน 30 วัน

15.1 KPI ปัจจุบัน

KPI	ค่าปัจจุบัน
จำนวน Backlog	1 โครงการ
อายุ Backlog	1 เดือน

KPI	ค่าปัจจุบัน
เวลาปิดงานเฉลี่ย	ยังไม่มีข้อมูล
ชั่วโมงคนที่ใช้ไป	ยังไม่มีข้อมูล
จำนวน Experiment	ยังไม่มีข้อมูล
Accuracy	ยังไม่มีข้อมูลตัวเลข
F1 / Recall / Precision	ยังไม่มีข้อมูล
จำนวน Error Categories	ยังไม่มีข้อมูล
จำนวน Blocked Items	ยังไม่มีข้อมูล

15.2 KPI เป้าหมายภายใน 30 วัน

เนื่องจากยังไม่มีข้อมูล Capacity และขนาดงานจริง ตัวเลขด้านล่างเป็น ข้อเสนอเริ่มต้นสำหรับการตั้งเป้า ไม่ใช่ผลที่รับประกันได้

KPI	เป้าหมายเบื้องต้น
ลดอายุ Backlog	ลดลงอย่างน้อย 50% หรือมี Decision ที่ปิดสถานะได้
ลดเวลาที่ใช้กับงานซ้ำ	20–30%
ลดเวลาเตรียม Evaluation Report	50%
ลดเวลาสร้าง Documentation	50%
เพิ่มสัดส่วน Experiment ที่มี Hypothesis	100%
เพิ่มสัดส่วน Model ที่ทำซ้ำผลได้	100% ของ Baseline และ Candidate
ลดการทดลองที่ไม่มีเกณฑ์ผ่าน	100%
เพิ่มสัดส่วน Work Items ที่มี Owner	100%

KPI ที่ควรเพิ่ม

Backlog Health

- จำนวนวันตั้งแต่มีการอัปเดตล่าสุด

- จำนวนวันติดสถานะ Blocked
- จำนวนงานที่ไม่มี Owner
- จำนวนงานที่ไม่มี Next Action
- จำนวนงานที่เกิน Deadline

AI Development Health

- Experiment Cycle Time
- Evaluation Cycle Time
- Reproducibility Rate
- Data Quality Issue Rate
- Label Agreement
- Regression Failure Rate
- Model Performance by Scenario

คำแนะนำ

อย่าตั้งเป้าเพียง “Accuracy ต้องเพิ่มขึ้น” แต่ให้วัดด้วยว่า:

เราสามารถระบุสาเหตุของ Error และตัดสินใจรอบถัดไปได้เร็วขึ้นหรือไม่?

16. FUTURE PREVENTION — ระบบป้องกัน Backlog

16.1 Early Warning System

Trigger	Threshold เบื้องต้น	Owner	Action
งานไม่มี Update	3 วันทำการ	Project Owner	แจ้งเตือน
Experiment ไม่มี Hypothesis	ทันที	Data Scientist	หยุดก่อนเริ่ม
Metric ไม่มี Baseline	ทันที	ML Lead	สร้าง Baseline
Blocked นานเกินไป	3 วันทำการ	Project Owner	Escalate
ไม่มี Next Action	ทันที	Task Owner	กำหนด Action
ไม่มี Clinical Reviewer	ก่อนเริ่ม Validation	Project Owner	แต่งตั้ง Reviewer

Trigger	Threshold เบื้องต้น	Owner	Action
Accuracy ลดลงจาก Baseline	ตาม Threshold ที่ตกลง	ML Lead	Regression Review
Data Drift	ตามเกณฑ์ที่กำหนด	Data Scientist	ตรวจสอบข้อมูล
Deadline ใกล้ถึงแต่ยังไม่มี Decision	5 วันทำการก่อนกำหนด	Project Owner	Decision Meeting
Threshold เหล่านี้เป็นข้อเสนอเริ่มต้น ต้องปรับตาม SLA และวิธีทำงานจริงของหน่วยงาน			

16.2 Dashboard ที่ควรมี

Project Health

- Project Status
- Backlog Age
- Blocked Days
- Next Milestone
- Owner
- Deadline
- Risk Level

Model Health

- Current Model Version
- Baseline Metrics
- Latest Metrics
- Performance Trend
- Error Distribution
- Data Version
- Last Evaluation Date

Governance Health

- Clinical Review Status
- Data Access Status
- Privacy Review Status
- Approval Status
- Decision Log

16.3 Weekly Review

ใช้เวลา 30 นาที ตอบ 5 คำถาม:

1. สัปดาห์นี้มีหลักฐานอะไรเพิ่มขึ้น?
2. Error หลักเปลี่ยนไปอย่างไร?
3. งานใด Blocked?
4. ต้องการการตัดสินใจจากใคร?
5. สัปดาห์หน้าจะทำอะไรให้โครงการเข้าใกล้การปิดงาน?

16.4 Monthly Review

ประเมิน:

- โครงการยังตอบโจทย์องค์กรหรือไม่
- ผลประโยชน์ที่คาดหวังคุ้มค่ากับ Effort หรือไม่
- Model Improvement ยังมีแนวโน้มที่ดีหรือไม่
- มีความเสี่ยงใหม่หรือไม่
- ควรดำเนินการต่อ เปลี่ยน Scope หรือยุติหรือไม่

สัญญาณว่า Backlog กำลังจะกลับมา

- งานไม่มี Acceptance Criteria
- Experiment เพิ่มขึ้นแต่ผลไม่ดีขึ้น
- ไม่มีการบันทึกเหตุผลของการเปลี่ยน Model
- ไม่มีเวลาที่สงวนไว้สำหรับงานสำคัญ
- ทุกคนเข้าใจคำว่า “เสร็จ” ไม่เหมือนกัน
- งานต้องรอการตัดสินใจแต่ไม่มี Escalation
- เอกสารและโค้ดไม่สอดคล้องกัน
- Data Version เปลี่ยนโดยไม่มีการประเมินผลใหม่
- ไม่มีการทบทวนคุณภาพของข้อมูลและ Label

17. ACTION PLAN

17.1 แผนปฏิบัติการหลัก

ลำดับ	Action	Deliverable	Owner	Priority
1	กำหนด Clinical Definition	Approved Definition	Clinical Owner + DS	P0
2	รวบรวมข้อมูลโครงการ	Evidence Pack	DS	P0
3	ตรวจ Dataset และ Label	Data Audit Report	DS + Reviewer	P0
4	Freeze Baseline	Baseline Model + Metrics	DS	P0
5	สร้าง Evaluation Pipeline	Reproducible Evaluation	DS / ML Engineer	P0
6	ทำ Error Analysis	Error Report	DS + Clinical Reviewer	P0
7	จัดลำดับ Experiment	Experiment Backlog	DS + ML Lead	P1
8	ทดลองแบบ Time-boxed	Experiment Result	DS	P1
9	Review ผล	Decision Record	Project Owner	P1
10	Validation / Pivot / Stop	Decision Package	Sponsor + Clinical	P1

17.2 Owner ที่ควรมี

Role	ความรับผิดชอบ
Data Scientist	Data, Model, Evaluation, Experiment
ML Engineer	Pipeline, Reproducibility, Deployment Feasibility
Clinical Owner	นิยาม Compliance และ Clinical Review
Data Owner	สิทธิ์และคุณภาพข้อมูล
Project Owner	Scope, Deadline, Dependency, Decision
Security / Privacy	การปกป้องข้อมูล
ML Lead	Technical Review
Sponsor	ตัดสินใจด้านทรัพยากรและ Go / No-Go

ปัจจุบันมีข้อมูลยืนยันเพียงบทบาท Data Scientist ดังนั้นชื่อบุคคลและ Owner รายอื่นยังต้องแต่งตั้ง

18. 7-Day Plan

เป้าหมายของสัปดาห์แรกไม่ใช่การเพิ่ม Accuracy ให้สูงที่สุด แต่คือการทำใหัรู้ว่า ปัญหาอยู่ตรงไหน และควรทดลองอะไรต่อ

วัน	งาน	ผลลัพธ์
Day 1	รวบรวม Code, Dataset, Logs, Metrics, Notes	Project Inventory
Day 2	กำหนด Clinical Definition และ Acceptance Criteria Definition Draft	
Day 3	ตรวจ Dataset, Label และ Data Split	Data Audit
Day 4	Freeze Baseline และสร้าง Evaluation Script	Baseline Report
Day 5	วิเคราะห์ Error Samples	Error Taxonomy
Day 6	สร้าง Experiment Cards 2–3 รายการ	Prioritized Experiment Plan
Day 7	Review กับ Clinical / ML Lead	Decision: Improve / Pivot / Stop

ผลลัพธ์ที่ต้องได้เมื่อจบ 7 วัน

- รู้ว่า Accuracy ปัจจุบันเท่าใด
- รู้ว่า Error หลักคืออะไร
- รู้ว่าข้อมูลเชื่อถือได้เพียงใด
- รู้ว่าต้องทดลองอะไรต่อ
- รู้ว่าใครต้องตัดสินใจ
- รู้ว่าโครงการมีโอกาสปิดได้ด้วย Scope ปัจจุบันหรือไม่

19. 30-Day Plan

Week 1: Establish Evidence

- Clinical Definition
- Data Audit
- Baseline
- Evaluation Pipeline
- Error Analysis

Milestone: มีหลักฐานเพียงพอสำหรับเลือกแนวทางพัฒนา

Week 2: Targeted Improvement

- เลือก Error ที่มีผลกระทบสูง
- สร้าง Experiment Cards
- ทดลองเฉพาะ Hypothesis ที่สำคัญ
- ประเมินกับ Baseline
- บันทึกผล

Milestone: มีผลเปรียบเทียบที่ทำซ้ำได้

Week 3: Validation Readiness

- ตรวจ Scenario Coverage
- ตรวจ False Negative
- ตรวจ Robustness
- ตรวจ Data Quality
- สรุป Risk Register
- เตรียม Clinical Review

Milestone: มีหลักฐานสำหรับตัดสินใจด้าน Validation

Week 4: Decision & Close

- Review ผลกับผู้เกี่ยวข้อง
- ตัดสินใจ Go / Iterate / Pivot / Stop
- จัดทำ Documentation
- ปิด Work Packages ที่เสร็จแล้ว
- บันทึกสิ่งที่ยังค้างพร้อม Owner
- กำหนดแผนรอบถัดไป

Milestone: โครงการมีสถานะที่ชัดเจนและมีหลักฐานรองรับ ไม่ใช่เพียง “ยังอยู่ระหว่างพัฒนา”

20. สิ่งที่เราควรเริ่มทำ “วันนี้”

ภารกิจ 90 นาที

0–15 นาที: Freeze Scope

เขียนคำตอบให้ได้:

ScrubSense ต้องตรวจจับเหตุการณ์อะไร และใครจะใช้ผลลัพธ์?

หากยังตอบไม่ได้ ให้สร้างรายการคำถามสำหรับ Clinical Owner

15–30 นาที: สร้าง Evidence Inventory

รวบรวม:

- Code Repository
- Model Checkpoint
- Dataset
- Annotation
- Evaluation Script
- Experiment Log
- Result Report
- Clinical SOP
- Meeting Notes

30–50 นาที: สร้าง Baseline Record

บันทึก:

- Model Version
- Dataset Version
- Metric
- Evaluation Date
- Data Split
- Known Limitations

50–70 นาที: สร้าง Error Taxonomy

เลือกตัวอย่างที่ทำนายผิดและแบ่งประเภท

Error ID

Input / Scenario

Ground Truth

Prediction

Error Type

Possible Cause

Severity

Evidence

Next Experiment

70–90 นาที: สร้าง Decision Brief

ส่งให้ Project Owner หรือ Clinical Owner เพื่อขอคำตอบ 5 เรื่อง:

1. นิยาม Compliance
2. เกณฑ์ผ่าน
3. ข้อมูลที่อนุมัติให้ใช้
4. Deadline
5. ผู้อนุมัติผล

21. คำตอบสำคัญ 3 ข้อ

A. งานค้างใดที่จริง ๆ แล้วไม่ควรทำต่อ?

จากข้อมูลปัจจุบัน ยังไม่สามารถสรุปว่า **ScrubSense** ทั้งโครงการไม่ควรทำต่อ ได้ เพราะยังไม่มีข้อมูลด้านคุณค่าทางธุรกิจ ความสำคัญทางคลินิก ต้นทุน และผลการประเมินที่แท้จริง

แต่สิ่งที่ควรหยุดทันทีคือ:

การทดลอง **Model** ใหม่แบบไม่มี **Hypothesis**, ไม่มี **Baseline** และไม่มีเกณฑ์ตัดสินใจ

หากตรวจสอบแล้วพบว่า:

- ไม่มี Use Case ที่ชัดเจน
- Clinical Owner ไม่ต้องการผลลัพธ์
- ข้อมูลไม่สามารถใช้ได้อย่างถูกต้อง
- ต้นทุนสูงกว่าประโยชน์อย่างมีนัยสำคัญ

- ไม่มีวิธีที่เป็นไปได้ในการประเมินความถูกต้อง
- ไม่สามารถควบคุมความเสี่ยงได้

จึงควรเสนอ **Pivot หรือ Stop** อย่างเป็นทางการ

B. งานค้างใดที่ AI สามารถช่วยลดเวลาได้มากที่สุด?

สำหรับ ScrubSense งานที่มีศักยภาพลดเวลามากที่สุดคือ:

1. Evaluation Automation

AI และ Coding Tools ช่วยสร้าง Pipeline ที่คำนวณ Metric และสร้างรายงานซ้ำได้

ประโยชน์:

- ลดงานคำนวณด้วยมือ
- ลดความผิดพลาด
- เปรียบเทียบ Model Version ได้เร็วขึ้น
- ทำ Regression Test ได้ง่ายขึ้น

2. Error Analysis Assistance

AI ช่วยจัดกลุ่ม Prediction ที่ผิดและค้นหา Pattern

แต่ต้องระวังว่า การตีความว่าเหตุการณ์ใดผิดหรือถูกในบริบท **Surgical Scrub** ต้องอาศัย **Ground Truth** และผู้เชี่ยวชาญ

3. Documentation Automation

AI สามารถเปลี่ยน Experiment Logs เป็น:

- Technical Report
- Executive Summary
- Decision Brief
- Risk Register
- Model Card
- Experiment Summary

4. Experiment Planning

AI ช่วยจัดลำดับ Hypothesis และสร้าง Experiment Card ทำให้ลดการทดลองที่ไม่เป็นระบบ

ข้อสรุป: AI มีแนวโน้มลดเวลางานสนับสนุนการพัฒนาได้มากกว่าการรับประกันว่า AI จะทำให้ Accuracy เพิ่มขึ้น

C. หากต้องลด Backlog ลง 50% ภายใน 30 วัน ควรทำ 5 เรื่องใดก่อน?

เนื่องจากมี Backlog เพียง 1 โครงการ การลดลง 50% ไม่สามารถตีความเป็นการลดจำนวนโครงการจาก 1 เหลือ 0.5 ได้โดยตรง จึงควรใช้ **Work Packages, Blocked Items และ Cycle Time** เป็นตัววัดแทน

5 เรื่องที่ควรทำก่อน

1. กำหนด Definition of Done และ Acceptance Criteria

ไม่ให้โครงการค้างเพราะไม่รู้ว่าจะ “เสร็จ” หมายถึงอะไร

2. Freeze Baseline และสร้าง Evaluation Pipeline

ทำให้ทุกการทดลองมีจุดเปรียบเทียบและสามารถทำซ้ำได้

3. ทำ Error Analysis จากข้อมูลจริง

หยุดการลองวิธีใหม่แบบไร้ทิศทาง และเลือกแก้ปัญหาที่มีหลักฐาน

4. จัดทำ Decision Gate พร้อม Clinical Owner

กำหนดว่าจะ Improve, Pivot, Pilot หรือ Stop เมื่อใด

5. Time-box การพัฒนาและจัดการ Dependency

สงวนเวลาสำหรับ ScrubSense ระบุ Owner ของทุก Blocker และ Escalate เรื่องที่ Data Scientist ตัดสินใจเองไม่ได้

22. สรุปเชิงผู้บริหาร


ScrubSense ไม่ควรถูกมองว่าเป็นเพียงโครงการที่ “โมเดลยังไม่แม่นยำ” แต่เป็นโครงการที่ต้องเปลี่ยนจากการทดลองเชิงเทคนิคแบบต่อเนื่อง ไปสู่ กระบวนการพัฒนา AI ที่มีหลักฐาน เกณฑ์ผ่าน และจุดตัดสินใจชัดเจน

ลำดับที่เหมาะสมคือ:

Clinical Definition



Data & Ground Truth



สิ่งที่สำคัญที่สุดใน 7 วันแรกไม่ใช่การสร้างโมเดลที่ซับซ้อนขึ้น แต่คือการสร้าง **Evidence Pack + Baseline + Error Analysis + Decision Gate**

หากทำได้ครบ จะเปลี่ยนสถานะของโครงการจาก:

“ยังไม่แม่นยำและยังไม่รู้จะลองอะไรต่อ”

เป็น:

“รู้ว่าโมเดลผิดตรงไหน มีหลักฐานอะไรบ้าง และมีทางเลือกที่ชัดเจนสำหรับการตัดสินใจ”

ข้อมูลที่ต้องการเพิ่มเติมเพื่อทำแผนเฉพาะ ScrubSense ให้แม่นยำขึ้น

หากต้องการให้การวิเคราะห์หรือรอบถัดไปลงลึกถึงระดับ **Model Architecture, Dataset Strategy, Experiment Plan และ Code-Level AI Workflow** ควรมีข้อมูลอย่างน้อยดังนี้:

1. ScrubSense ใช้ ภาพหรือวิดีโอ?
2. ต้องตรวจจับอะไรบ้าง เช่น ท่าทาง การเคลื่อนไหว ลำดับขั้นตอน หรือระยะเวลา?
3. Model ปัจจุบันคืออะไร?
4. Accuracy ปัจจุบันเท่าใด และวัดจาก Dataset ไດ?

5. มีจำนวนวิดีโอ/ภาพและ Label เท่าใด?
6. Error ที่พบมากที่สุดคืออะไร?
7. มีตัวอย่าง Prediction ที่ผิดหรือไม่?
8. เป้าหมาย Accuracy หรือ Metric ที่ต้องการคือเท่าใด?
9. Deadline ที่แท้จริงคือวันไหน?
10. มี Clinical Reviewer หรือผู้อนุมัติแล้วหรือยัง?

เมื่อมีข้อมูลเหล่านี้ จึงสามารถออกแบบแผนแก้ **Accuracy** แบบเจาะจงและประเมินความเป็นไปได้ของการปิดงานภายใน **30 วัน** ได้อย่างมีหลักฐานมากขึ้น